

Practical session 5: A non-differentiable, convex function

JALAL DOUIRI | FERRAN DALMAU

Optimization Techniques, UPF

15 de junio de 2019

1. Duality based Methods for Convex Optimization

1.1. Min - Max Theorem

Sigui $L : X \times Y \rightarrow \mathbb{R}$ una funció amb dues variables, $x \in X$ i $y \in Y$ llavors sempre tenim que:

$$\max_y \min_x L(x, y) \leq \min_x \max_y L(x, y)$$

Assumint que el mínim i el màxim de la funció existeix.

1.2. Duality Gap

$$DG = \min_x \max_y L(x, y) - \max_y \min_x L(x, y) \geq 0$$

Si el Duality Gap es igual a 0 ($DG = 0$), en un punt (x_0, y_0)

on x_0 fa mínim $L(x_0, y_0)$ i y_0 fa màxim $L(x_0, y_0)$

tenim un punt de sella.

($DG=0$ es una condició necessària)

1.3. Lagrangian Duality

$$L(x, \lambda, \mu) = f(x) - \sum_{i=1}^k \lambda_i c_i(x) - \sum_{j=1}^r \mu_j d_j(x)$$

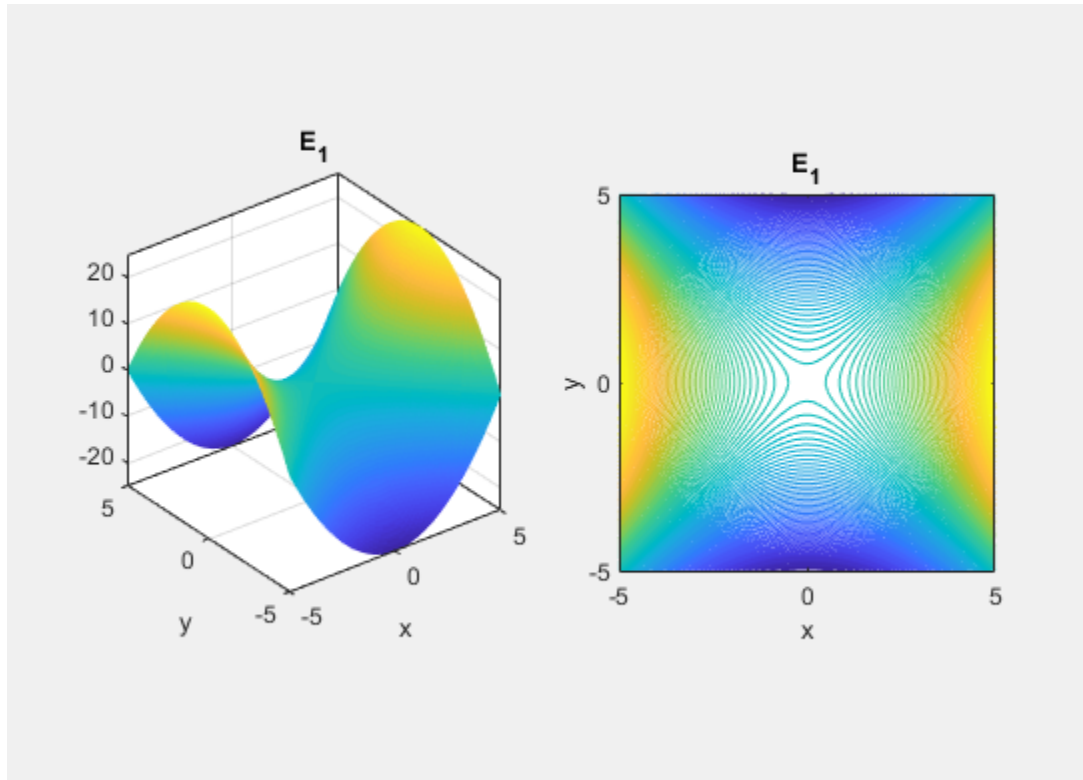
d_j restriccions de desigualtat

c_i restriccions d'igualtat


2. Minimization of a convex non-differentiable function

2.1. Removing the non-differentiability with an auxiliary variable


- 2.1.1. Run *toy_saddle_points.m* and determine which of the functions displayed presents a saddle point and which do not.




La primera equació que és la $E_1(x, y) = x^2 - y^2$, té un punt de sella en el punt $(0,0)$.



La segona equació, és la $E_2(x, y) = 2x + y$, No és cap punt sella.



La tercera equació, és la $E_3(x, y) = x^2 + y^2$, No és cap punt sella.

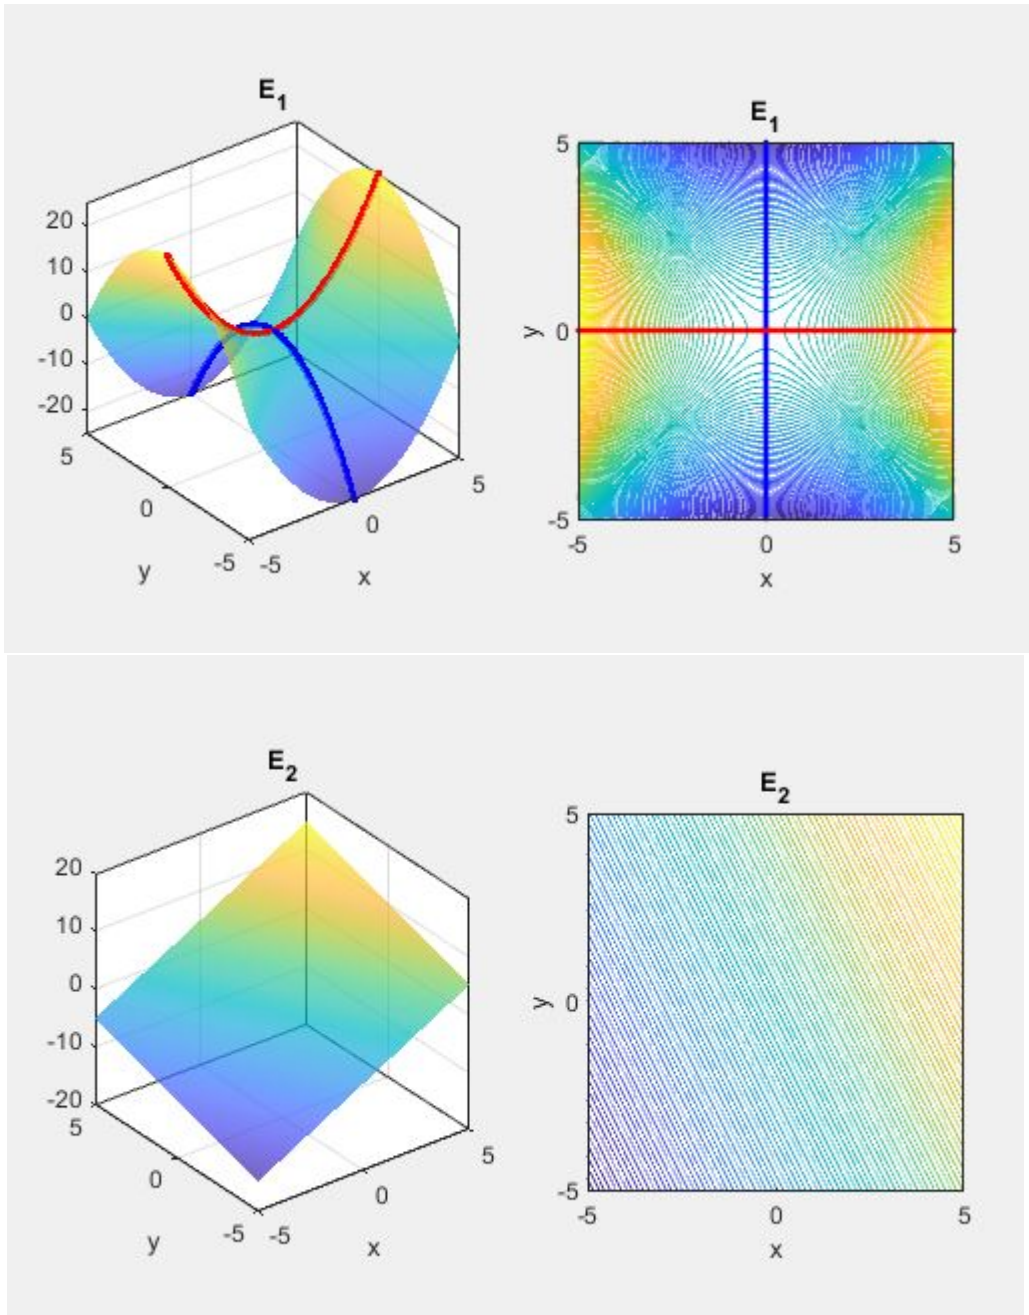


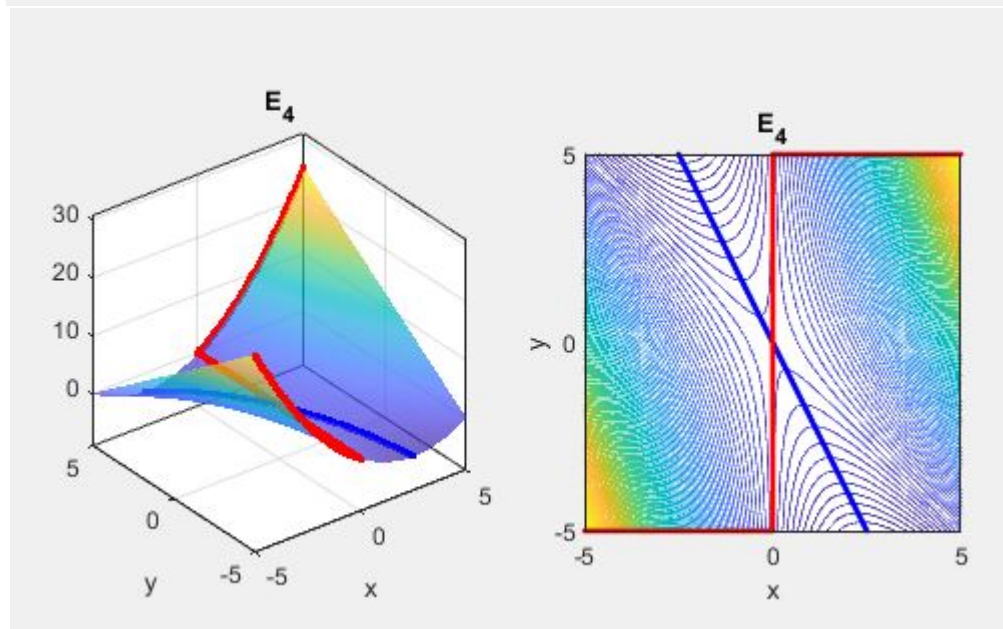
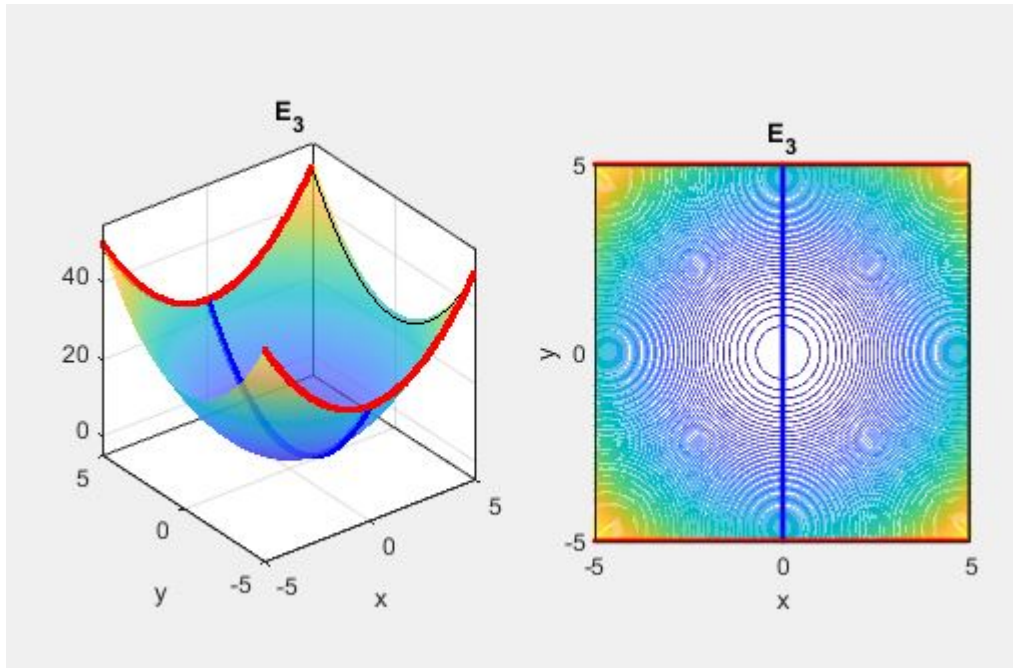
La quarta equació, és la $E_4(x, y) = \cos(\frac{3}{5}(x + y))$, No és cap punt sella.


2.2. The primal-dual problem: finding a saddle point

Al executar els archius `plot_saddel_point1`, `plot_saddel_point2`, `plot_saddel_point3`, `plot_saddel_point4`, `plot_saddel_point5`, en les funcions que tenen un saddle point ens troba el punt, el metode utilitzat en aquests fitxers, és el buscar el maxim de la part concava, y el minim de la part convexa, com podem observar en el grafic de la funció E1, troba perfectament el punt sella, el qual es el (0,0), la linea vermella es el min en funció de X, que seria la convexa y el blau el max en funció de Y.

La Figura de la E2, es un punt, la qual cosa no té ni convexitat ni concavitat, La E3, en compilar-se el minim de y que es la linea blava, es compleix i passa per el minim, pero el max de x dista molt dels punts que passa la Y, la qual cosa deduem que només hi ha un minim i cap punt de sella, La E4, es troben el min de y y el max de x, el E5 conte molts minims y maxims la qual cosa es més complexa de explicar.







2.2.1. Complete the MatLab function `toy_primal_dual.m`. Follow the comments provided in the code.

`toy_primal_dual.m`

```
x_old = x;    % this is just for display
y_old = y;    % this too
grad_x = (transpose(A)*y) + (1/lambda)*(x-b);
% update x by gradient descent with step delta
x = x_old - theta*(grad_x);
% update y by gradient ascent with step theta
v = y_old+(delta*A*x);
y = v/max(1,sqrt(sum(v.^2)));
```

2.3. The dual problem: constrained maximization

2.3.1. Complete the MatLab function *toy_dual.m*. Follow the comments provided in the code.

toy_dual.m

```
v = y_old+(delta*A*x);
y = v/max(1,sqrt(sum(v.^2)));
% compute primal variable as  $\hat{x}(y)$ 
x_old = x;
x = b-(lambda*transpose(A)*y);
```

Compute cost in toy_dual.m and toy_primal_dual.m

```
Ax = A*x;
E1 = sqrt(sum(Ax.^2));
E2 = sum((x - b).^2);
E = E1 + (1/(2*lambda))*E2;
P = E;
Atxi = A'*y;
D = b'*Atxi - lambda/2*sum(Atxi.^2);
PD = repmat(E2,[dmg_sz 1])/(2*lambda) + y'*Ax;
dual_gap = P - D;
```

2.3.2. Run the MatLab scripts *toy_problem_R1.m* and *toy_problem_R2.m*. Explain the plots that are displayed in each case. Try different parameters as suggested in the comments in the code

Como se puede observar tanto entre las figuras 4 y 5 como entre las figuras 8 y 9, se puede observar la implementacion primal dual tiende a tener mas iteraciones que dual. Esto es debido en gran parte a que en **Dual** el punto optimo de x por una y determinada es determinado de forma directa, y no de forma iterativa con gradient descent.

Figura 1: Primal Dual starting point (3,0)

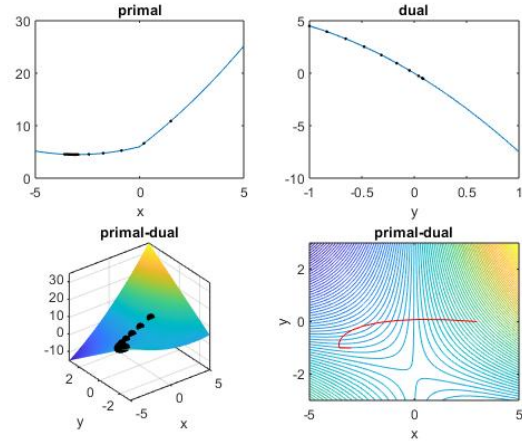


Figura 2: Primal Dual starting point (b,0)

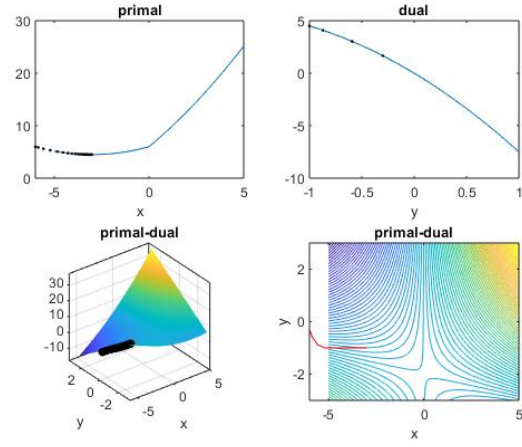


Figura 3: Dual starting point (b,0)

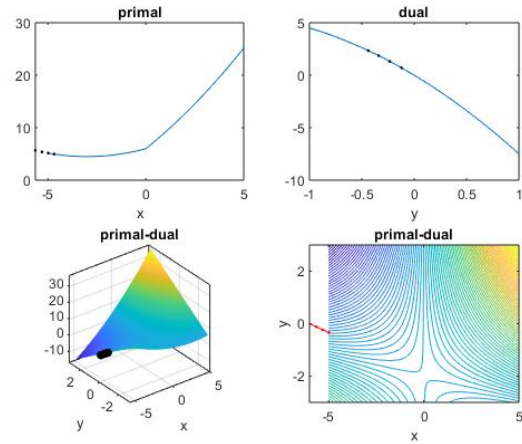


Figura 4: Primal dual iterations starting point (b,0)

```
-> it 31 :: 1000 -> |P( x(k) ) - D( y(k) )| = 4.32632e-05
-> it 32 :: 1000 -> |P( x(k) ) - D( y(k) )| = 3.00439e-05
-> it 33 :: 1000 -> |P( x(k) ) - D( y(k) )| = 2.08638e-05
-> it 34 :: 1000 -> |P( x(k) ) - D( y(k) )| = 1.44887e-05
-> it 35 :: 1000 -> |P( x(k) ) - D( y(k) )| = 1.00616e-05
-> it 36 :: 1000 -> |P( x(k) ) - D( y(k) )| = 6.98724e-06
```

Figura 5: Primal dual iterations starting point (b,0)

```
it 6 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 1.57183
it 7 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 1.15541
it 8 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.801478
it 9 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.501908
it 10 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.249584
it 11 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.0382653
it 12 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0
```

Figura 6: Primal Dual starting point (b,0)




Figura 7: Dual starting point (b,0)

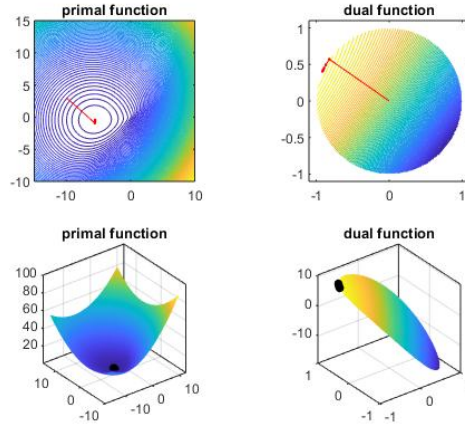


Figura 8: Primal Dual iterations starting point (b,0)

```
-> it 14 :: 1000 -> |P( x(k) ) - D( y(k) )| = 0.00148026
-> it 15 :: 1000 -> |P( x(k) ) - D( y(k) )| = 0.000812803
-> it 16 :: 1000 -> |P( x(k) ) - D( y(k) )| = 0.000450603
-> it 17 :: 1000 -> |P( x(k) ) - D( y(k) )| = 0.000251695
-> it 18 :: 1000 -> |P( x(k) ) - D( y(k) )| = 0.000141303
-> it 19 :: 1000 -> |P( x(k) ) - D( y(k) )| = 7.95406e-05
```

Figura 9: Dual iterations starting point (b,0)

```
-> it 3 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.0150329
-> it 4 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.00399406
-> it 5 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.00103551
-> it 6 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 0.000265029
-> it 7 :: 1000 -> |P( x^(y(k)) ) - D( y(k) )| = 6.73832e-05
```

2.4. The dual gap and the stopping condition

Compute cost in toy_dual.m and toy_primal_dual.m

```
Ax = A*x;
E1 = sqrt(sum(Ax.^2));
E2 = sum((x - b).^2);
E = E1 + (1/(2*lambda))*E2;
P = E;
Atxi = A'*y;
D = b'*Atxi - lambda/2*sum(Atxi.^2);
PD = repmat(E2,[dmg_sz 1])/(2*lambda) + y'*Ax;
dual_gap = P - D;
```

El criterio usado es la variable `dual_gap`, que indica la diferencia (gap) entre la funcion dual (**variable D**) y la primal (**variable P**), y cuando esta tiende a cero significa que hemos encontrado el punto que minimiza la funcion primal sometido a las constraints, con lo cual paramos de iterar.